

Capstone Project

截止日期：2026.6.21

任务：组成 3 人团队，通过讲述一个数据故事（参考第一节课的例子），展示你在课堂上学到的数据科学技能。自选题目，提出原始问题，收集相关数据，对数据进行清洗、整理和分析，得出结论并进行展示和汇报。大作业占总成绩的 50%，其中课堂展示和书面报告分别占 20 分和 30 分。注意 3 名成员在各项工作中应尽量平衡工作量，包括课堂展示和撰写报告。分析内容没有强制要求的主题，但请注意以下几点：

- 数据收集与清洗是数据科学中的重要内容。在选择要分析的数据时，鼓励从多个来源收集数据，尤其是通过网络爬虫。鼓励使用包含缺失值的脏数据和非结构化数据。不鼓励使用他人已整理好的、格式规整的表格数据。
- 探索性数据分析是数据科学中的另一个重要内容。其目的是理解变量的整体分布和关系，提供初步的洞察和假设，并揭示或设计用于预测的重要特征。
- 数据可视化可以是项目的重要组成部分，但不建议可视化部分超过整体工作的 50%。
- 由于机器学习不是本课程的内容，如要使用，建议比例不要太大（因为你整体是通过机器学习以外的工作得分的）。
- 课堂汇报将在第 15、16 周进行，每组汇报 15 分钟。将提前 1 周随机生成小组排序。
- 大作业将以组为单位提交到网络学堂。提交内容包括**论文、课堂展示 PPT、代码和数据**。
- 关于使用 AI 的政策：本课鼓励在学习过程中使用 AI，包括向 AI 咨询某处代码具体如何写。但同学应保证掌握所提交大作业的所有内容，并保证提交的代码和分析均为自己完成。**批改过程中将针对疑似 AI 生成的痕迹，请相应同学现场复现代码和分析过程，如无法现场复现，将按【作弊】依据校规处理。**
- 报告的风格应类似于一篇短论文，包含以下部分：引言（背景、意义和文献综述）、方法（数据收集、清洗和分析方法）、结果、讨论和结论。行文正式，语句完整，逻辑清晰。具体参考论文的书写标准。

- 大作业将根据你在项目中所展示的数据科学技能、投入的努力程度、创新性、分析的逻辑性、写作的清晰度和详细程度等进行考评。在报告末尾请标注每位作者的具体贡献，根据贡献和相应部分质量进行个体化打分。
- 如果数据集过大，可上传至你的清华云盘 <https://cloud.tsinghua.edu.cn>，并在报告中提供下载链接。
- 报告的提交日期是第 17 周的周日（6 月 21 日）。**包含毕业班同学的小组须提前一周，在第 16 周的周日（6 月 14 日）提交，否则会影响毕业。**
- 截止日期没有延期，请同学们规划好时间。